

Assignment 5 — Piano di Strategia (direzione del gruppo)

Robust Low-Risk Core con tilt Learning-to-Rank multi-fattore, ottimizzato al netto dei costi

QPMwP — Spring 2026 · Deadline 30.06.2026 12:00 CEST · Documento di pianificazione v1

0. Tesi in un paragrafo

In un universo equity mono-paese da ~157 nomi, l'unico edge davvero robusto e fuori campione è sul **lato rischio**, non sul lato rendimento atteso (il programma lo dice esplicitamente — §5/OLZ: *"il rischio è più prevedibile del rendimento"*; anomalia low-vol). Quindi la spina dorsale della strategia è un allocatore **risk-based** (minimum-variance / ERC) con covarianza shrinkata, che storicamente batte il cap-weighted su Sharpe e — soprattutto — su drawdown. Sopra questo core montiamo un **tilt cross-sezionale multi-fattore** stimato con un modello **learning-to-rank** (soddisfa il requisito ML in modo sostanziale, non cosmetico). Il rendimento extra arriva dal tilt; la stabilità e il basso drawdown arrivano dal core; il risultato netto si vince con il **controllo del turnover**. Battiamo lo SPI principalmente sul **risk-adjusted** (Sharpe, MaxDD, beta stabili), con il rendimento come spinta secondaria. È performance quantificabile ottenuta onestamente — non un numero gonfiato che è la firma di un leakage.

1. Razionale economico

1.1 Dove sta l'edge affidabile

Markowitz è un minimizzatore di varianza per costruzione, e la critica di Michaud ("error maximization") è che, trattando input stimati come verità, carica peso sugli asset i cui rendimenti sono più sovrastimati. Chopra–Ziemba (1993): per avversione al rischio moderata, gli errori sulle medie (μ) distruggono ~un ordine di grandezza più utilità degli errori sulle varianze. **Conseguenza progettuale:** non costruiamo la performance su $\hat{\mu}$ (fragile). La costruiamo sulla struttura di rischio (Σ), che è più stabile e più prevedibile.

Questo è il motivo per cui il core è risk-based e μ -free.

1.2 Perché il core risk-based dà performance, non solo difesa

L'anomalia low-vol (§5) è documentata e persistente: i titoli a bassa volatilità ottengono rendimenti cumulati più alti e drawdown più bassi del cap-weighted ("win more by losing less"), contro-CAPM. Il minimum-variance porta naturalmente verso questi nomi. In equity CH/EU questo si traduce storicamente in Sharpe sensibilmente superiore al benchmark e MaxDD molto più contenuto. **Non è overfitting: è un premio al rischio noto in letteratura.**

1.3 Perché l'ML è un tilt, non il motore

Un modello learning-to-rank conosce l'**ordinamento**, non le magnitudini (è ordinale per costruzione). Usarlo come motore dei rendimenti attesi (à la `risk_aversion=10000`) reintroduce la fragilità di $\hat{\mu}$ che vogliamo evitare. Usarlo come **inclinazione** sopra un portafoglio già robusto è il modo corretto: aggiunge rendimento dove il segnale è affidabile, senza che un errore di ranking distrugga il profilo di rischio. La loss listwise (NDCG, LambdaMART) è scelta "con l'applicazione in mente" (lezione LTR): premia l'ordine e pesa la cima della lista, esattamente ciò che serve a una strategia a quintili.

1.4 Perché il net-of-cost è il vero campo di battaglia

I costi imposti dalla consegna (1%/anno fissi + 0.2% per ribilancio) e la bassa breadth dell'universo rendono il **turnover** la variabile che separa una strategia viva da una morta. Due leve: (i) il core risk-based ancora i pesi a strutture che si muovono lentamente, quindi il turnover di base è basso; (ii) una **penalità di turnover** esplicita nell'optimizer (§3, linearizzazione L1) ottimizza direttamente al netto.

2. Dati, universo e benchmark (realtà verificata)

2.1 Cosa abbiamo davvero

Il repo pubblico contiene solo CSV aggregati. I **panel** veri li ha il corso:

File	Contenuto	Copertura	Ruolo nel progetto
<code>market_data.parquet</code>	prezzi / volumi per titolo	(dal corso)	rendimenti, Σ , liquidità, simulazione

jkp_data.parquet	caratteristiche JKP per titolo	(dal corso)	feature del segnale ML
spi_index.csv	rendimenti giornalieri SPI	1999-01-02 → 2024-04-30	benchmark
symbols.csv	157 nomi, settore, FIGI	—	definizione universo
jkp_factor_series_che_eqw.csv	13 serie fattoriali L-S svizzere (EW)	1988 → 2010	attribuzione del report
msci_country_indices.csv , NDDLWI.csv	indici paese / MSCI World	1999+	contesto / risk-on-off opzionale

Universo: 157 titoli (154 CH), 11 settori (Industrials 34, Financials 32, Health Care 28, Real Estate 13, Materials 12...). Concentrato e mono-paese → vincoli settoriali e bassa breadth sono il contesto di tutto.

2.2 Il benchmark da battere (numeri reali)

SPI, periodo intero 1999–2024: **rendimento annuo 3.35%, vol annua 14.01%, Sharpe 0.239, MaxDD –54.9%** (GFC). Ultimi 5 anni: Sharpe 0.282, MaxDD –26.3%.

Il gancio strategico: il punto debole dello SPI è il drawdown (–55%). Il punto di forza del nostro core è proprio tagliare il drawdown. La tesi del report è: *stesso o migliore rendimento, metà del drawdown, Sharpe 2–3×*.

3. Architettura: la scala (4 rung + benchmark)

Manteniamo la disciplina “un ingrediente alla volta” così ogni differenza di performance è attribuibile a una causa singola. Universo, calendario e costi **identici** su tutti i rung (è un esperimento solo se sono identici).

- **S0 — SPI:** benchmark.
- **S1 — Min-Variance core:** Σ Ledoit-Wolf, vincoli settoriali + box, long-only, full-invest. *Nessun segnale.* È il pavimento robusto; dovrebbe già battere lo SPI su Sharpe e MaxDD. Isola il contributo della **sola costruzione di rischio**.
- **S2 — Core + tilt lineare:** composito z-score multi-fattore (stile Assignment 4) come

tilt soft. Isola il contributo del **segnale lineare**.

- **S3 — Core + tilt Learning-to-Rank:** XGBRanker (LambdaMART) al posto del composito lineare. Isola il contributo di **non-linearità + ranking loss**.
- **S4 — Modello completo:** tilt LTR + **regime-aware risk scaling** + ottimizzazione turnover-aware netta. Isola il contributo dell'**adattività**.

Claim pre-registrati: (i) S1 batte SPI su Sharpe/MaxDD; (ii) S2 batte S1 sul rendimento risk-adjusted; (iii) $S3 \geq S2$ su IC e metriche di portafoglio; (iv) S4 batte S3 specificamente in regime di alta vol / bassa dispersione, e ~pareggia altrove. Successo realistico: qualche decimo di Sharpe tra i run, drawdown visibilmente più bassi del benchmark, beta più stabili.

4. Specifica per componente (mappata al rubric di coding, 15 pt)

4.1 Selection (`bibfn_selection.py` via `SelectionItemBuilder`)

- **Riusa:** `gaps` (continuità prezzi), `min_volume` (tradabilità).
- **Custom #1 — `feature_coverage`** : tiene solo i titoli con tutte le feature non-NA alla data (universo ML = universo backtest; l'optimizer non chiede mai al segnale un titolo che non ha potuto rankare).
- **Custom #2 — screen di qualità/vol (opzionale, sensitività):** esclude l'ultimo decile per qualità o il primo per volatilità realizzata. *Earns custom-selection credit* con filtri che hanno una ragione economica.

4.2 Optimization data & constraints (`bibfn_optimization_data.py` , `bibfn_constraints.py` via `OptimizationItemBuilder`)

- **Dati:** rendimenti 3y (365×3 giorni di calendario — i dati hanno i weekend!), `fill_value=0` solo dopo i filtri gaps/volume; cap weights per l'ancora; media **aritmetica** (la geometrica è marcata sbagliata in `optimization_1`).
- **Σ:** stima **Ledoit-Wolf** (target a correlazione costante o single-index) — vedi §6.
- **Vincoli:** full-invest ($\sum w_i = 1$), long-only, box per nome (es. 5%), **bande settoriali** vs benchmark (es. $\pm 5\%$ del peso settoriale SPI). **Custom constraint builder** per le bande settoriali → ulteriore credito.

4.3 Signal generation (ML — requisito esplicito)

- **Feature:** caratteristiche JKP per titolo (momentum `ret_6_1 / ret_12_1` con skip-month, value `be_me`, quality `qmj / qmj_safety / qmj_growth`, profitability `gp_at / op_at`, investment `at_gr1`, leverage `debt_me`, accruals `oaccruals_at`, **low_risk**). Sign-flip per i premi negativi. Z-score + winsorize cross-sezionale per data.
- **Label:** rank percentile del rendimento del mese successivo (bounded, ordinale — la NDCG con gain esponenziale esplode su rank grezzi).
- **Modello:** `XGBRanker(objective='rank:ndcg', ndcg_exp_gain=False)`, walk-forward stride-1, `PanelTimeSeriesSplit` (mai shuffle su panel temporale), retuning annuale con caching.
- **Diagnostica (OOS):** IC di Spearman per data + t-stat; train-vs-test IC; tabella decili; SHAP; hit-rate. **Allarme leakage:** IC medio > 0.15 ⇒ audit prima di tutto.
- Baseline lineare Ridge come **diagnostica** (separa “non-linearità” da “ranking loss” senza un quinto backtest).

4.4 Optimization model (classe custom — criterio di voto esplicito)

Classe che eredita da `Optimization`, implementa `set_objective` e `solve`. Dettaglio matematico in §5. È qui che vive la fusione core-risk + tilt + penalità turnover → è *il contributo*.

4.5 Simulation

Walk-forward mensile, costi fissi 1%/anno + 0.2% per ribilancio, turnover annualizzato riportato. Stesso `BacktestData` per tutti i rung.

5. L'optimizer custom (matematica)

Forma “mean-risk” del §5, con il termine di rischio **dominante** e il segnale come inclinazione. A ogni data di ribilancio risolviamo un QP:

$$\begin{aligned} \text{\$ \$ } w^{\star} = \arg \min_{w \in \Omega} \{ & \underbrace{w^{\top} \Sigma w}_{\text{rischio (core)}}; -; \underbrace{\gamma, s^{\top} w}_{\text{tilt segnale}}; +; \underbrace{\lambda_{\text{TO}}}_{\text{penalità turnover}} \} \\ & \text{\$ \$ } \end{aligned}$$

con $\Omega = \{ \mathbf{1}^{\top} w = 1, ; 0 \leq w_i \leq u_i, ; \ell_g \leq \mathbf{1}_g^{\top} w \leq u_g \}$

$\forall g, \text{settore } g, \text{ } \$$.

- Σ : covarianza Ledoit-Wolf 3y (§6). s : score del segnale (rank z-score o output LTR), standardizzato cross-sezionalmente così γ ha scala stabile nel tempo.
- γ (intensità del tilt): **basso** — il baricentro è sul rischio. Fissato ex-ante (non tunato sul backtest); un'unica sensitività su $\{0, \gamma_{\text{low}}, \gamma_{\text{mid}}\}$.
- λ_{TO} : penalità turnover, linearizzata con $w = w^+ - w^-$, $w^{\pm} \geq 0$, $\|w - w_{\text{prev}}\|_1 = \mathbf{1}^{\text{top}}(w^+ + w^-)$ (§3). Augment del problema con i blocchi $w^{\pm}$.
- $\gamma = 0 \Rightarrow$ recupera il **minimum-variance puro** (rung S1): test di sanità che la classe degrada correttamente.

Varianti (sensitività, off di default): ERC (NLP, §5) come base alternativa; max-diversification ($\text{DR} = w^{\text{top}} \sigma / \sqrt{w^{\text{top}} \Sigma w}$). Mostrare che min-var-tilt e ERC-tilt danno conclusioni coerenti è materiale da report.

`solve : qpsolvers / cvxopt con P=2Σ , q=-γs , vincoli A,b,G,h,ell,u$.`

6. Stima della covarianza (il cuore della performance)

Con ~100 nomi su ~756 osservazioni giornaliere, $n < T$ ma la matrice campionaria è rumorosa e quasi-singolare lungo le direzioni a basso autovalore — proprio quelle su cui il min-variance carica peso (Σ^{-1} amplifica gli autovalori piccoli). **Tutto l'edge dipende da una buona Σ .**

- **Ledoit-Wolf shrinkage** verso target a correlazione costante (o single-index): $\hat{\Sigma} = \delta F + (1 - \delta) S$, con δ ottimale in forma chiusa. È la versione principata dello shrinkage Ridge insegnato nel corso (§3).
- **Check di condizionamento:** $\text{cond}(\Sigma)$ su date campione; se esplode, Ridge add-on $\Sigma + \lambda I$ (materiale del corso) documentato.
- **Annualizzazione/scala daily** coerente con γ e λ .

7. Overlay di regime (rung S4 — complessità + performance, disciplinato)

Scaliamo l'esposizione lorda / l'intensità del tilt in base a un indicatore di regime **pre-**

specificato, non tunato:

- **Concentrazione degli autovalori** della matrice di correlazione (quota del primo autovalore): in crisi sale → mercato “un solo fattore” → riduci il tilt e spingi verso min-variance puro.
- In alternativa o in combinazione: regime di **vol realizzata** (terzili).

Regola: in regime di alta concentrazione/vol, $\gamma \downarrow$ e si stringe verso il core difensivo; in regime calmo, γ torna al livello base. Questo è §4 (regimi) + §6, ed è un de-risking, non un market-timing. Tenuto semplice e dichiarato ex-ante per non scivolare nell’overfitting.

8. Valutazione & report (15 pt)

- **Tabella 5-way (S1–S4 + SPI)**: rendimento annuo, vol, Sharpe, Sortino, MaxDD, Calmar, turnover, tracking error, Information Ratio — **gross e net** (VC=0.002; variante fc=0.01).
- **Grafici**: equity cumulata (log), rendimenti rolling 3y, Sharpe rolling, curva di drawdown (qui si vede il taglio vs SPI), pesi/esposizioni settoriali nel tempo.
- **Subperiodi**: ultimi 5 anni; **bull vs bear** definiti ex-ante via drawdown SPI (bear: dotcom 2002-03, GFC 2008-09, COVID 2020, shock tassi 2022). Atteso: il core **vince in bear** e tiene il passo in bull.
- **Attribuzione**: regressione dei rendimenti della strategia sulle **13 serie fattoriali JKP svizzere** (e FF/MOM dai parquet dove disponibili) → mostra il caricamento su `low_risk / quality`. Beta rolling per i rungs con tilt. *Nota copertura*: le serie JKP del CSV arrivano al 2010; l’attribuzione full-period userà i fattori dai parquet.
- **Sensitività (override di una riga)**: $\gamma \in \{0, \text{low}, \text{mid}\}$; base Σ (Ledoit-Wolf / Ridge); base risk (min-var / ERC); regime overlay on/off; costi gross/net; finestra Σ 2y/3y.

9. Target di performance realistici (onesti, ancorati ai numeri veri)

Metrica	SPI (reale)	Target strategia (gross)	Razionale
			premio low-vol + tilt

Sharpe	0.239	0.5 – 0.7	qualità
MaxDD	-54.9%	-25% / -35%	min-variance taglia la coda
Rendimento annuo	3.35%	~3.5 – 5.5%	comparabile o lievemente sopra
Turnover	—	basso (ancora lenta + penalità)	dove si vince il netto

Sono **target, non promesse**. Net-of-cost sarà più basso del gross. Il messaggio difendibile è *risk-adjusted*, non “rendimento monstre”.

10. Guardrail di onestà (pre-registrati, prima dei risultati)

- **IC medio mensile > 0.15** ⇒ firma di leakage, non skill → audit dello shift delle label.
- **Net Sharpe > 2** in questo universo ⇒ firma di un bug → audit prima di festeggiare.
- Niente look-ahead: feature laggate, esecuzione t+1, walk-forward, normalizzazioni solo su passato.
- Niente survivorship: universo a copertura continua via il filtro coverage.
- La bassa breadth (mono-paese, segnali lenti correlati nel tempo) limita l'IR ottenibile per Grinold: lo diciamo prima.

11. Come questo assorbe il meglio della proposta esistente (per il gruppo)

Questa direzione **non butta** il lavoro del compagno: lo riusa e lo mette in sicurezza.

- La **macchina LTR** (feature, label, walk-forward, IC, SHAP) diventa il nostro generatore di segnale per S2/S3 — invariata.
- I **guardrail di onestà** e la disciplina della **scala a un ingrediente per volta** sono adottati pari pari.
- L'idea **Black-Litterman / IC-Ω** del compagno può rientrare come **sensibilità o rung opzionale S5**: ancorare il tilt all'equilibrio invece che alla penalità di turnover. Così la sua eleganza metodologica resta valorizzata, ma non è più il *motore* fragile della performance.

- Differenza chiave da spiegare al gruppo: nella sua proposta il segnale ML è il motore e il BL lo ancora (può collassare al benchmark per costruzione); qui il **portafoglio risk-based è il motore** con un pavimento di performance robusto, e l'ML è il tilt. Più difendibile sul netto e fuori campione.

12. Divisione del lavoro

Modulo	Owner	Effort	Gate
T0 — data layer, universo, Σ Ledoit-Wolf, prior	Membro 1	~2g	$\text{cond}(\Sigma)$ ok, universo congelato
T1 — selection (incl. custom) + S1 min-var	Membro 1	~1g	S1 batte SPI su Sharpe/MaxDD
T2 — segnale ML (LTR + Ridge diagnostico)	Membro 2	~4g	IC t-stat > 1.5, no leak alarm
T3 — optimizer custom + S2/S3	Owner idea	~3g	$\gamma=0 \Rightarrow$ min-var; vincoli ok ogni data
T4 — overlay regime + S4	Owner idea	~2g	unit test regime, de-risking corretto
T5 — valutazione, attribuzione, report HTML	Finisher	~3g	run da kernel fresco, claim tracciabili

Nessuno costruisce sul `data_layer` prima che il suo gate sia verde e il modulo congelato.

13. Tracciabilità (ogni scelta cita il corso)

Scelta di design	Fonte nel corso
Core risk-based, μ -free	§5 OLZ ("rischio più prevedibile del rendimento"), Michaud/Chopra-Ziemba
Min-variance / ERC / max-div	§5 mean-risk template, risk decomposition §2
Σ Ledoit-Wolf / Ridge	§3 regolarizzazione covarianza, $n > T$

Bande settoriali, box, turnover L1	§3 constraints + linearizzazione
Learning-to-rank, NDCG, no shuffle	lezione LTR (§10), loss con l'applicazione in mente
Tilt non motore	§2 error maximization, fragilità di $\hat{\mu}$
Walk-forward, IC, biases	§4 backtesting, §6 ML, TimeSeriesSplit
Overlay regime (eigenvalue concentration)	§4 regimi, §6
Attribuzione su fattori JKP/FF	§7 factor investing
Allarmi leakage (IC>0.15, Sharpe>2)	§4 deflated Sharpe / data-snooping

Prossimo passo dopo l'OK al piano: T0 — data layer e stima Ledoit-Wolf, partendo dai CSV per la struttura e poi sui parquet del corso per i numeri.